Université Hassan 1er

ÉCOLE NATIONALE DE COMMERCE ET DE GESTION DE SETTAT

COMPTE RENDU DE PROJET

Estimation de la Taille du Secteur Informel par Région

Modèle de Prédiction par Régression — Machine Learning

Module	Machine Learning en Finance
Filière	L3 S8 — ENCG Settat
Réalisé par	Wiam FAHIM / Meryem FAKLANI
Période	Année Universitaire 2024–2025

I. Introduction

Le secteur informel constitue une composante importante de l'économie marocaine. Il influence la croissance économique, l'emploi et les recettes fiscales. Cependant, sa mesure reste complexe en raison de son caractère non déclaré.

I.1 Objectif du projet

Ce projet vise à estimer et prédire la taille du secteur informel (exprimée en pourcentage du PIB régional) à l'aide de modèles de Machine Learning basés sur la régression. L'analyse s'appuie sur des données couvrant les 12 régions marocaines sur la période 2014–2023.

II. Description des Données

II.1 Structure du dataset

Le dataset mobilisé pour cette étude présente les caractéristiques suivantes :

- 12 régions marocaines
- Période d'observation : 2014 – 2023
- 120 observations au total

II.2 Variables utilisées

Le tableau ci-dessous récapitule les variables explicatives retenues dans le modèle ainsi que leurs descriptions respectives :

Variable	Description
pib_regional	PIB régional (en milliards MAD)
taux_chomage	Taux de chômage (%)
taux_pauvrete	Taux de pauvreté (%)
alphabetisation	Taux d'alphabétisation (%)
densite_pop	Densité de population
part_agri	Part de l'agriculture (%)
acces_finance	Accès aux services financiers (%)
taux_urbanisation	Taux d'urbanisation (%)
annee	Année
taille_informel	Taille du secteur informel (% PIB) — Variable cible

III. Analyse Exploratoire (EDA)

III.1 Distribution de la variable cible

La taille du secteur informel varie entre 10 % et 70 % du PIB régional, traduisant une forte dispersion entre les régions marocaines. Cette hétérogénéité justifie le recours à des modèles de régression capables de capturer les dynamiques spécifiques à chaque territoire.

III.2 Analyse des corrélations

L'analyse des corrélations met en évidence deux groupes de variables selon leur impact sur le niveau d'informalité :

Variable	Sens de l'impact	Interprétation
Taux de chômage	Positif (+)	Plus le chômage est élevé, plus l'informel progresse
Taux de pauvreté	Positif (+)	La précarité économique favorise les activités informelles
Part agricole	Positif (+)	Les économies rurales agricoles génèrent davantage d'informalité
Alphabétisation	Négatif (−)	Un niveau d'éducation élevé réduit le recours à l'informel
Accès à la finance	Négatif (−)	L'inclusion financière favorise la formalisation
Taux d'urbanisation	Négatif (−)	Les zones urbaines structurent mieux l'activité économique

En synthèse, les régions pauvres et rurales affichent les niveaux d'informalité les plus élevés, tandis que les régions développées et urbanisées présentent une économie davantage formalisée.

IV. Préparation des Données

IV.1 Étapes de prétraitement

- Encodage des régions par la méthode One-Hot Encoding
- Normalisation des variables quantitatives
- Division des données : 80 % pour l'entraînement, 20 % pour le test

IV.2 Validation croisée

Une validation croisée de type K-Fold (k = 5) a été appliquée afin d'assurer la robustesse et la généralisation des modèles entraînés.

V. Modèles de Machine Learning Utilisés

Cinq modèles de régression ont été entraînés et comparés dans le cadre de cette étude :

- Régression Linéaire
- Ridge (régularisation L2)

- Lasso (régularisation L1)
- Random Forest
- Gradient Boosting

VI. Résultats et Comparaison des Modèles

VI.1 Tableau de performance

Le tableau ci-dessous présente les métriques d'évaluation obtenues pour chaque modèle :

Modèle	RMSE	MAE	R^2	CV R^2
Régression Linéaire	~	~	~	~
Ridge	~	~	~	~
Lasso	~	~	~	~
Random Forest	~	~	~	~
Gradient Boosting	~	~	~	~

Le meilleur modèle est sélectionné sur la base du R^2 le plus élevé. Une valeur de R^2 proche de 1 indique une forte capacité explicative du modèle.

VI.2 Interprétation des métriques

- RMSE (Root Mean Squared Error) : une valeur faible indique une bonne précision des prédictions
- MAE (Mean Absolute Error) : une valeur faible traduit des erreurs de prédiction réduites
- R^2 : proche de 1, le modèle est performant ; proche de 0, il est peu explicatif

VII. Analyse du Modèle Optimal

VII.1 Réel vs Prédit

Le nuage de points comparant les valeurs réelles aux valeurs prédites constitue un indicateur clé de la qualité du modèle. La concentration des points autour de la diagonale principale témoigne d'une bonne adéquation entre les prédictions et les observations.

VII.2 Analyse des résidus

La distribution aléatoire des résidus autour de zéro confirme l'absence de biais systématique dans le modèle et valide les hypothèses de la régression.

VIII. Importance des Variables

L'analyse de l'importance des variables déterminée par le modèle optimal révèle le classement suivant :

Rang	Variable	Rôle
1	Taux de chômage	Facteur déterminant — impact positif fort
2	Taux de pauvreté	Facteur socio-économique majeur
3	Part agricole	Indicateur de ruralité et d'informalité structurelle

Ces résultats confirment que les facteurs socio-économiques — notamment la pauvreté, le chômage et la structure productive rurale — influencent fortement le niveau d'informalité régionale.

IX. Prédictions 2024–2028

IX.1 Hypothèses retenues

- Croissance annuelle du PIB régional : +3,5 %
- Baisse progressive du taux de chômage
- Amélioration continue de l'accès aux services financiers

IX.2 Résultats prévisionnels

Sur la base de ces hypothèses, le modèle prédit une diminution progressive du poids du secteur informel à l'horizon 2028. Cette tendance est toutefois différenciée selon les régions, les zones les plus rurales et les plus pauvres étant susceptibles d'afficher une convergence plus lente.

X. Analyse Régionale

Profil	Caractéristiques	Niveau d'informalité
Région la plus informelle	Forte pauvreté, économie rurale, faible alphabétisation	Élevé (> 50 % du PIB régional)
Région la moins informelle	Urbanisée, accès à la finance, alphabétisation élevée	Faible (< 20 % du PIB régional)

XI. Interprétation Économique

XI.1 Facteurs qui augmentent l'informalité

- Chômage élevé : absence d'opportunités dans le secteur formel
- Pauvreté : contrainte économique conduisant aux activités informelles
- Dominance agricole : secteur structurellement moins formalisé

XI.2 Facteurs qui réduisent l'informalité

- Éducation et alphabétisation : accès à l'emploi formel et conscience fiscale
- Urbanisation : densité des services, des entreprises et des administrations
- Inclusion financière : accès au crédit, aux assurances et aux systèmes de paiement formels

---

XII. Limites de l'Étude

- Données synthétiques : les résultats ne reflètent pas la réalité terrain
- Simplification des phénomènes : le secteur informel est multidimensionnel
- Variables manquantes : fiscalité, corruption, réglementation, qualité des institutions

---

XIII. Recommandations

Sur la base de l'analyse conduite, les recommandations suivantes peuvent être formulées à destination des décideurs publics :

- Améliorer l'éducation et l'alphabétisation, en particulier dans les zones rurales
- Développer l'inclusion financière via des produits adaptés aux populations précaires
- Encourager l'urbanisation planifiée et l'accès aux services publics
- Créer des emplois formels et simplifier les démarches d'enregistrement des entreprises

---

XIV. Conclusion

Ce projet démontre la pertinence du Machine Learning pour aborder des problématiques économiques complexes telles que l'estimation du secteur informel. Les modèles de régression permettent d'identifier les déterminants structurels de l'informalité et d'orienter les politiques publiques vers les leviers les plus efficaces.

Au-delà des résultats quantitatifs, cette étude met en lumière l'importance des facteurs socio-économiques — chômage, pauvreté, ruralité — dans la persistance du secteur informel, et souligne le rôle central de l'éducation et de l'inclusion financière dans le processus de formalisation de l'économie marocaine.

XV. Livrables

- Code Python commenté (génération du dataset, EDA, modélisation, visualisations)
- Visualisations : distribution, matrice de corrélation, comparaison des modèles
- Graphiques de prédictions 2024–2028 par région
- Présent rapport au format DOCX